OTIMIZAÇÃO DE INSUMOS NA INDÚSTRIA 4.0

Welington dos Santos Sales

SUMÁRIO EXECUTIVO

Sistema baseado em Edge AI para otimização de custos na indústria cerâmica, calculando o Custo Real por Embalagem Efetiva (CRPE). A Empresa Alfa enfrenta decisões de compra baseadas apenas em custo unitário e defeitos iniciais, ignorando perdas no processo. Solução: Gateway Industrial coleta dados da máquina, modelo de IA leve classifica falhas em tempo real, dados são enviados à nuvem para dashboard acessível a operadores, supervisores e gestores. Funções: captura local, classificação de falhas, cálculo do CRPE, visualização e segurança. Aplica Arquitetura de Software, Ciência de Dados e Cybersecurity.

PROBLEMATIZAÇÃO

A Empresa Alfa atua no setor cerâmico, onde a eficiência operacional impacta diretamente a competitividade. Um gargalo informacional crítico ocorre no processo de embalagem. A empresa adquire embalagens de três fornecedores, com perfis conhecidos apenas na recepção (Tabela 1).

Tabela 1: Caracterização dos Fornecedores (Dados Anonimizados)

Fornecedor	Custo Unitário (R$)	Defeito Inicial	Classificação Interna
A	2,00	3%	Alta Qualidade
B	1,80	6%	Qualidade Aceitável
C	1,50	10%	Qualidade Baixa

Contudo, esta visão é incompleta. Durante a operação, falhas processuais (atolamentos, problemas de colagem, rasgos) causam paradas e desperdício. O sistema atual é composto por uma arquitetura isolada: uma máquina com log local não integrado, incapaz de: diferenciar falhas processuais de defeitos de fábrica; quantificá-las com precisão; e correlacioná-las ao fornecedor em uso. Esta lacuna gera decisões de compra baseadas em variáveis estáticas, ignorando o desempenho dinâmico. Um fornecedor mais barato pode

gerar custo total maior devido a mais falhas no processo. O problema evidencia a falta de integração vertical (dados operacionais não alcançam a gestão) e a ausência de uma estratégia de dados que considere armazenamento e segurança da informação para estes ativos digitais. A arquitetura atual não explora soluções em nuvem para análise e visualização, nem aborda os riscos cibernéticos inerentes à futura conexão de ativos industriais.

JUSTIFICATIVA E OBJETIVO GERAL

A intervenção justifica-se por um impacto triplo. Economicamente, calcular o CRPE identifica o fornecedor de menor custo total, gerando economia direta. Operacionalmente, a classificação automática de falhas viabiliza manutenção preditiva, aumentando a eficiência (OEE). Tecnicamente, aplica-se tendências como Edge Computing, IA leve e segurança cibernética proativa (norma IEC 62443), alinhando a empresa à Indústria 4.0. Academicamente, este projeto sintetiza o curso. Exige Arquitetura de Software para desenhar sistemas distribuídos Edge-Cloud; Ciência de Dados para modelar o KPI CRPE e algoritmos de classificação; e Cybersecurity para implementar controles robustos, protegendo dados industriais.

Objetivo Geral: Projetar e validar conceitualmente uma arquitetura de sistema baseada em Edge AI e governança de dados segura para monitoramento em tempo real da linha de embalagem, com o propósito de calcular o Custo Real por Embalagem Efetiva (CRPE) e identificar as causas-raiz das perdas, fornecendo suporte analítico objetivo para a decisão de compra de insumos na Empresa Alfa.

FUNDAMENTAÇÃO TEÓRICA

A proposta fundamenta-se em conceitos da transformação digital industrial. A **Indústria 4.0** preconiza a integração de sistemas ciber-físicos e decisões baseadas em dados (data-driven), onde a conexão entre o chão de fábrica e os sistemas de gestão permite maior eficiência e rastreabilidade (LIVEMES, [2026?]).

A **Computação de Borda (Edge Computing)** surge como paradigma complementar à computação em nuvem, processando dados próximo à fonte de geração. Isso reduz a latência, economiza banda de rede e aumenta a resiliência do sistema, sendo os gateways industriais os nós críticos dessa arquitetura (SHI et al., 2016). No contexto industrial, a

Edge Computing permite que decisões críticas sejam tomadas em milissegundos, sem dependência de conectividade com a nuvem.

A execução de Inteligência Artificial em dispositivos com recursos computacionais limitados é viabilizada pelo paradigma **TinyML**, que compreende técnicas de compressão, quantização e otimização de modelos para execução em microcontroladores e processadores embarcados (WARDEN; SITUNAYAKE, 2019). Dentro deste contexto, os **Modelos Específicos de Domínio (Domain-Specific Lightweight Models - DSLM)** são algoritmos de machine learning compactos, treinados para tarefas específicas e otimizados para execução em hardware com restrições de memória e processamento. Diferentemente de modelos genéricos de grande porte, os DSLMs priorizam a eficiência e a precisão em um domínio restrito, como a classificação de falhas em uma máquina de embalagem.

Frameworks como **TensorFlow Lite** e **ONNX Runtime** permitem a conversão e implantação desses modelos na borda, suportando inferência em tempo real com baixo consumo energético. A escolha entre essas tecnologias depende do hardware alvo e da complexidade do modelo.

A convergência entre Tecnologia Operacional (OT) e Tecnologia da Informação (IT) demanda abordagens de segurança robustas. A norma **IEC 62443** fornece o framework global para segurança em sistemas de automação e controle industriais, baseado em princípios como segmentação de rede, defesa em profundidade e gestão de riscos (INTERNATIONAL SOCIETY OF AUTOMATION, 2020). A prática de **MLSecOps (Machine Learning Security Operations)** estende os princípios de segurança ao ciclo de vida dos modelos de IA abordando questões como integridade dos dados de treinamento, proteção contra ataques adversariais e monitoramento contínuo de desvios (drift) do modelo em produção.

O indicador **CRPE (Custo Real por Embalagem Efetiva)** é uma adaptação do conceito de **Custo Total de Propriedade (Total Cost of Ownership - TCO)**, que avalia o custo completo de um ativo ao longo de seu ciclo de vida, incluindo aquisição, operação, manutenção e descarte (ELLRAM, 1993). No contexto do projeto, o CRPE incorpora não apenas o custo de aquisição da embalagem, mas também as perdas associadas a defeitos e falhas durante o processo produtivo.

Para a comunicação entre os componentes da arquitetura, emprega-se o padrão **MQTT (Message Queuing Telemetry Transport)**, protocolo leve e amplamente adotado para Internet das Coisas (IoT), que opera sobre o modelo publish-subscribe. A extensão **Sparkplug B** adiciona semântica e descoberta de dados ao MQTT, sendo particularmente adequada para ambientes industriais. Para integração futura com sistemas de supervisão, considera-se o protocolo **OPC UA (Open Platform Communications Unified Architecture)**, padrão maduro para interoperabilidade na indústria. Os serviços em nuvem adotam o modelo **PaaS (Platform as a Service)** para broker MQTT, banco de dados de séries temporais (InfluxDB) e dashboard (Grafana), assegurando escalabilidade, alta disponibilidade e gerenciamento simplificado.

PERCURSO METODOLÓGICO DA INTERVENÇÃO

A metodologia adotada é o **Design Science Research (DSR)**, abordagem adequada para projetar e avaliar artefatos tecnológicos que solucionam problemas identificados em contextos organizacionais (HEVNER et al., 2004). O percurso divide-se em três fases conceituais.

Fase 1 – Diagnóstico e Proposição: Envolve imersão no processo AS-IS via análise documental dos registros de produção e entrevistas com operadores, supervisores e gestores. Esta fase resulta no mapeamento detalhado do fluxo de embalagem e na especificação formal dos requisitos funcionais e não-funcionais do sistema.

Fase 2 – Desenvolvimento e Projeto da Solução: Nesta fase, desenha-se a arquitetura técnica completa. Especificam-se os protocolos de comunicação (OPC UA para aquisição da máquina, MQTT/Sparkplug B para comunicação com a nuvem) e a stack tecnológica (TensorFlow Lite para o modelo de IA, InfluxDB para armazenamento de séries temporais, Grafana para visualização). Paralelamente, elabora-se o framework de governança e segurança, com políticas alinhadas à IEC 62443 e MLSecOps, aplicando segurança em todas as camadas e o princípio do privilégio mínimo.

Especificação Detalhada da Abordagem de IA:

Para viabilizar a classificação automatizada das falhas, é necessário caracterizar precisamente os eventos observados na máquina de embalagem. Com base em análise de

equipamentos similares e entrevistas com especialistas, definem-se as seguintes categorias de falha:

Atolamento (Jamming): Ocorre quando a embalagem fica presa nos roletes ou guias da máquina. Causas possíveis incluem dimensões fora de especificação, variação na espessura do papelão ou umidade inadequada.

Falha de Colagem (Gluing Failure): As abas da embalagem não selam corretamente. Causas possíveis incluem papelão com baixa absorção, aplicador de cola desregulado ou cola com viscosidade inadequada.

Rasgo (Tearing): A embalagem rasga durante o fechamento ou manuseio. Causas possíveis incluem papelão de baixa gramatura, vincos mal executados ou fragilidade estrutural.

Desalinhamento (Misalignment): A embalagem não é posicionada corretamente para o fechamento. Causas possíveis incluem variações dimensionais ou problemas no alimentador.

Falha de Leitura de Código (Code Reading Failure): O sistema não consegue ler o código de barras ou QR code da embalagem. Causas possíveis incluem baixo contraste, sujeira ou danos na superfície.

Múltiplas Falhas: Ocorrência simultânea de dois ou mais tipos de falha.

Indeterminado: Eventos que não se enquadram nas categorias anteriores.

Fontes de Dados e Variáveis:

A aquisição de dados para o modelo de IA será realizada através de duas abordagens complementares, priorizando-se inicialmente a primeira devido à sua menor complexidade e requisitos computacionais:

Abordagem 1 – Dados de Sensores e Logs da Máquina (Prioritária): A máquina de embalagem moderna (ou retrofitada com sensores) disponibiliza uma série de sinais através de seu Controlador Lógico Programável (CLP). As variáveis a serem monitoradas incluem:

Códigos de erro: Gerados pelo próprio controlador da máquina (ex.: "erro 101 - atolamento na entrada").

Sensores de posição: Indicam se a embalagem está na posição correta em cada etapa.

Sensor de cola: Monitora a aplicação (tempo, pressão, temperatura).

Sensor de temperatura da cola: Garantia de viscosidade adequada.

Contador de ciclos: Número de embalagens processadas por minuto.

Tempo de ciclo por embalagem: Detecção de variações que podem indicar problemas.

Sensor de torque do motor: Picos podem indicar atolamento iminente.

Leitor de código: Confirmação de leitura bem-sucedida ou falha.

A **frequência de aquisição** destes dados será de **10 Hz (10 leituras por segundo)**, suficiente para capturar a dinâmica do processo, que opera a aproximadamente 20-30 embalagens por minuto. Os dados serão agregados em **janelas de 6 segundos** (correspondentes a 2-3 ciclos) para alimentar o modelo de classificação, permitindo detectar padrões temporais associados a falhas.

Abordagem 2 – Visão Computacional (Futura Expansão): Para casos mais complexos, como detecção de rasgos ou desalinhamentos sutis, uma câmera industrial poderia ser adicionada. Neste cenário, seriam geradas imagens ou frames de vídeo a **5 fps (quadros por segundo)**, exigindo um modelo de classificação de imagens (ex.: CNN - Rede Neural Convolucional) significativamente mais pesado, possivelmente inviabilizando a execução pura no gateway e demandando aceleração por hardware específico (ex.: Google Coral ou NVIDIA Jetson). A **viabilidade desta abordagem será avaliada na fase piloto**, optando-se inicialmente pela abordagem baseada em sensores.

Modelagem do Problema de IA:

O problema será modelado como uma **classificação de séries temporais multivariadas**. A cada janela de 6 segundos, o modelo receberá um tensor com dimensões (60 leituras x N variáveis) e deverá classificar a janela em uma das classes definidas anteriormente.

Técnicas de Modelagem e Viabilidade Edge:

A escolha da técnica de modelagem deve equilibrar acurácia e capacidade de execução no gateway industrial (ex.: ICP DAS tGW-700, com processador ARM e 512MB RAM). As seguintes opções serão avaliadas:

Modelos baseados em árvores (Random Forest, XGBoost): Leves e eficientes após engenharia de features (média, variância, tendência). Conversão para ONNX permite baixa latência. **Primeira opção.**

Redes Neurais Recorrentes (LSTM): Capturam dependências temporais longas, porém mais pesadas. Versões quantizadas podem ser viáveis, exigindo testes. **Alternativa se árvores tiverem baixa acurácia.**

Transformers de pequeno porte: Alta complexidade e consumo de memória. **Inviáveis sem aceleração dedicada.**

A **viabilidade da Edge AI** neste contexto é alta, conforme detalhado nas técnicas de modelagem apresentadas, que priorizam algoritmos leves compatíveis com o hardware proposto.

Caso a abordagem de visão computacional seja necessária, a arquitetura poderá ser revista para incluir um coprocessador de IA (Coral Edge TPU) conectado ao gateway, ou redirecionar o processamento de imagens para a nuvem (com as devidas considerações de latência e largura de banda).

Fase 3 – Validação Conceitual e Plano de Ação: Desenvolve-se um protótipo conceitual, com mockups do dashboard e um script de simulação do CRPE em Python. Formula-se um plano de implementação piloto com roadmap e análise de riscos.

Análise de Riscos e Mitigações:

Risco Técnico (Incompatibilidade): Mitigado pela especificação detalhada de hardware com suporte a múltiplos protocolos na Fase 2.

Risco de Segurança: Mitigado pelo framework Security-by-Design e controles da IEC 62443 (criptografia, segmentação, MFA).

Risco Operacional (Baixa Adoção): Mitigado pelo planejamento de capacitação e opção de leitor automático para lotes.

Risco do Modelo de IA (Baixa Acurácia): Mitigado pela governança do ciclo de vida do modelo (MLSecOps), com retreinamento e monitoramento contínuo de desvios. A estratégia inclui a coleta de dados rotulados para re-treinamento periódico e a possibilidade de evoluir para modelos mais complexos (LSTM) se necessário.

A arquitetura proposta atende aos requisitos de escalabilidade e disponibilidade: componentes em nuvem são dimensionáveis sob demanda (PaaS) e o gateway possui buffer local para até 24 horas de dados em caso de falha de conectividade. A extensibilidade é garantida pela modularidade, permitindo substituir componentes (ex.: o modelo de IA, o tipo de sensor) sem impactar o todo. A mobilidade é atendida pelo dashboard web acessível em qualquer dispositivo. Estratégias de backup e arquivamento de longo prazo são nativas nos serviços de nuvem selecionados (ex.: InfluxDB Cloud).

RESULTADOS ESPERADOS

Ao final do projeto conceitual, espera-se entregar um blueprint completo para um sistema de Governança de Edge AI. Os resultados diretos incluem: (1) especificação técnica da arquitetura com definição das variáveis monitoradas e estratégia de modelagem; (2) definição formal do KPI CRPE com fórmula e critérios de cálculo; (3) plano de implementação piloto com análise de riscos e cronograma; e (4) artefatos de validação conceitual (mockups do dashboard e simulações do CRPE em diferentes cenários). O impacto esperado para a Empresa Alfa é a transformação de um processo decisório subjetivo em um processo objetivo e baseado em dados, levando à otimização de custos com insumos, ao aumento da eficiência operacional (redução de paradas não programadas) e ao fortalecimento de sua posição competitiva através da adoção segura e bem-sucedida de princípios da Indústria 4.0.

REFERÊNCIAS

ELLRAM, L. M. A Taxonomy of Total Cost of Ownership Models. **Journal of Business Logistics**, Oak Brook, v. 14, n. 1, p. 171-191, 1993.

HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. Design Science in Information Systems Research. **MIS Quarterly**, Minneapolis, v. 28, n. 1, p. 75-105, 2004.

INTERNATIONAL SOCIETY OF AUTOMATION. **IEC 62443 Series: Security for industrial automation and control systems**. Research Triangle Park: ISA, 2020.

LIVEMES. **Indústria 4.0 e o Futuro da Produção: Guia Completo para Entender e Aplicar o Novo Modelo Industrial**. [S. l.: s. n.], [2026?]. E-book.

SALES, W. S. **Otimização de Insumos na Indústria 4.0: Artefatos Complementares**. GitHub, 2026. Disponível em: https://github.com/WelingtonSales/otimizacao-insumos-industria4.0-optimization-inputs-industry4.0.git. Acesso em: 18 fev. 2026.

SHI, W. et al. Edge Computing: Vision and Challenges. **IEEE Internet of Things Journal**, Piscataway, v. 3, n. 5, p. 637-646, 2016.

WARDEN, P.; SITUNAYAKE, D. **TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers**. Sebastopol: O'Reilly Media, 2019.

ANEXOS

ANEXO A: Tabela Detalhada de Requisitos

Requisitos Funcionais (RF)

ID	Descrição	Prioridade
RF-01	Coletar logs de eventos da máquina de embalagem via gateway.	Alta
RF-02	Permitir registro manual/automático do lote/fornecedor em uso.	Alta
RF-03	Classificar cada falha em categorias pré-definidas via DSLM no gateway.	Alta
RF-04	Calcular automaticamente o CRPE para cada fornecedor/lote ativo.	Alta
RF-05	Enviar dados agregados de forma segura para a nuvem.	Média
RF-06	Exibir em dashboard o CRPE e ranking dos fornecedores A, B e C.	Alta
RF-07	Gerar alertas visuais para CRPE acima do limite ou pico de falhas.	Baixa

Requisitos Não-Funcionais (RNF)

ID	Categoria	Descrição	Critério de Aceitação
RNF-01	Desempenho	Latência da classificação no gateway ≤ 100ms.	≤ 100ms
RNF-02	Disponibilidade	Sistema no gateway com 99,5% de uptime no turno.	99,5%
RNF-03	Segurança	Comunicações criptografadas com TLS 1.2+.	Uso de TLS 1.2+
RNF-04	Segurança	Controle de acesso ao dashboard com MFA.	Implementação de MFA
RNF-05	Confiabilidade	Buffer de dados local para até 24h sem conexão.	24h de buffer
RNF-06	Usabilidade	Filtros no dashboard acionáveis em ≤ 3 cliques.	Filtros intuitivos
RNF-07	Manutenibilidade	Atualização remota (OTA) do modelo de IA no gateway.	Atualização OTA funcional

ANEXO B: Diagramas de Arquitetura

Figura B1: Diagrama de Contexto

